

Корреляционная структура

Многомерные гауссовы модели. Обратная к ковариационной матрица. Разреживание. Блочный оптимизационный подход. Графическое Lasso.

ПМИ ФКН ВШЭ, 1 декабря 2018 г.

Алексей Артемов^{1,2}

¹Сколтех ²ФКН ВШЭ

Оглавление

- › Многомерные гауссовы системы
- › Факторизация совместных распределений наблюдаемых
- › Понятие графических моделей
- › Выборочная ковариационная матрица и ℓ_1 -регуляризация оценки
- › Блочнo-координатный метод оптимизации регуляризованного правдоподобия
- › Lasso-метод оптимизации регуляризованного правдоподобия
- › Алгоритм QUIC

Мотивация выявления структуры

Мотивация выявления структуры

- › Размерность задач в современной статистике чрезвычайно высокая
 - › 10^3 котировок акций, 10^6 вокселей МРТ, 10^8 пользователей Facebook, ...
 - › Объем выборки даже бывает меньше размерности!
- › Естественно желание снизить размерность описания соответствующих задач
- › Один из способов это сделать — исключить корреляционные зависимости между некоторыми наблюдаемыми

Мотивация выявления структуры




Рис.: Пример зависимости между 6 переменными (наличие связи обозначается ребром в графе).

Hallac D. et al. Network inference via the time-varying graphical lasso // Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. — ACM, 2017. — С. 205-213. MLA

Мотивация выявления структуры

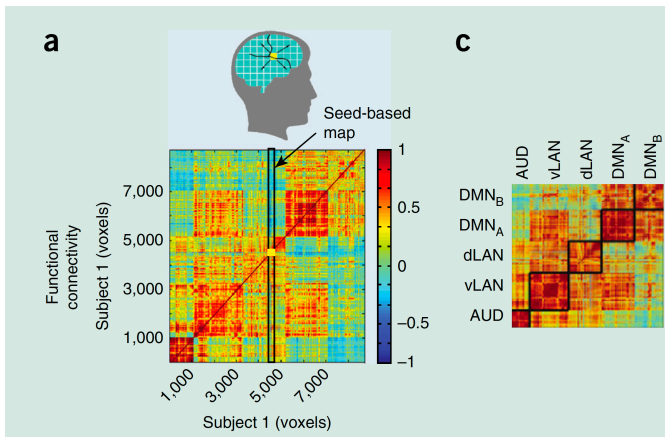


Рис.: Функциональная связность при полном корреляционном пововксельном анализе: а: корреляция между выбранным RoI (желтый цвет) и остальными вокселями; с: пововксельные ковариационные матрицы описывают организацию подсетей у испытуемого.

Cohen, Jonathan D., et al. "Computational approaches to fMRI analysis." *Nature neuroscience* 20.3 (2017): 304.
Алексей Артемов

Многомерные гауссовы системы

Многомерные гауссовы системы

Определение (Многомерный гауссовский вектор)

Это случайный вектор $\mathbf{x} \in \mathbb{R}^n$, имеющий распределение вида

$$f(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^n \det \Sigma}} \exp \left\{ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right\}$$

› **Пример:** двумерное нормальное распределение $(\mathbf{x} = (x_1, x_2)^\top \in \mathbb{R}^2)$ имеет плотность

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \times \right. \\ \left. \times \left[\frac{(x_1 - \mu_1)^2}{\sigma_1^2} - \rho \frac{2(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_1\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right] \right\}$$

Многомерные гауссовы системы

- › Соответствующая ковариационная матрица равна

$$\Sigma = \mathbb{E}[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^\top] = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}$$

- › Случай $\rho = 0$: отсутствие корреляций (независимость!)
- › Как запишется плотность $\mathbf{x} \in \mathbb{R}^2$?

Многомерные гауссовы системы

- › Соответствующая ковариационная матрица равна

$$\Sigma = E[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T] = \begin{bmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}$$

- › Случай $\rho = 0$: отсутствие корреляций (независимость!)
- › Как запишется плотность $\mathbf{x} \in \mathbb{R}^2$?
- › Ковариационная матрица диагонализуется: $\Sigma = \text{diag}(\sigma_1^2, \sigma_2^2)$,
а для плотности выполнена факторизация

$$\begin{aligned} f(x_1, x_2) &= \frac{1}{2\pi\sigma_1\sigma_2} \exp \left\{ -\frac{1}{2} \left[\frac{(x_1 - \mu_1)^2}{\sigma_1^2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right] \right\} = \\ &= \frac{1}{\sqrt{2\pi\sigma_1^2}} \exp \left\{ -\frac{(x_1 - \mu_1)^2}{2\sigma_1^2} \right\} \\ &\quad \times \frac{1}{\sqrt{2\pi\sigma_2^2}} \exp \left\{ -\frac{(x_2 - \mu_2)^2}{2\sigma_2^2} \right\} \end{aligned}$$

Понятие графической модели


- › Говорят, что распределение P факторизуется по ненаправленному графу G , если для совместной плотности $f(\mathbf{x})$ выполнено:

$$f(\mathbf{x}) = Z^{-1} \prod_{A \in \mathcal{A}} \phi_A(\mathbf{x}_A),$$

где \mathcal{A} — подмножества графа

- › Здесь переменные $x = \{x_v, v \in V\}$, $\mathbf{x}_A = \{x_v, v \in A\}$ индексируются узлами графа
- › Такая факторизация соответствует марковскому свойству: $A \perp\!\!\!\perp B | S$, если S отделяет A от B в графе

Понятие графической модели



› Граф выше соответствует факторизации

$$f(\mathbf{x}) = \psi_{12}(x_1, x_2)\psi_{13}(x_1, x_3)\psi_{24}(x_2, x_4)\psi_{25}(x_2, x_5) \times \\ \times \psi_{356}(x_3, x_5, x_6)\psi_{47}(x_4, x_7)\psi_{567}(x_5, x_6, x_7)$$

Гауссовы графические модели

- › Пусть $\mu = 0$, тогда

$$f(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^n \det \Sigma}} \exp \left\{ -\frac{1}{2} \mathbf{x}^\top \Sigma^{-1} \mathbf{x} \right\} \\ \propto \det \Theta \exp \left\{ -\frac{1}{2} \mathbf{x}^\top \Theta \mathbf{x} \right\},$$

где $\Sigma = E[\mathbf{x}\mathbf{x}^\top]$ и $\Theta = \Sigma^{-1}$

- › Структура фиксируется в ковариационной матрице: если матричный элемент $\Theta_{ij} = 0$, то $x_i \perp\!\!\!\perp x_j$
- › Условная независимость \equiv разреженность

Задача оценивания корреляционной структуры

Стандартные статистические оценки

- › Пусть задана выборка $\mathbf{X}^\ell = \{\mathbf{x}_i\}_{i=1}^\ell$
- › Почему бы не использовать выборочную ковариационную матрицу:

$$\hat{\Sigma} = \frac{1}{\ell - 1} \sum_{i=1}^{\ell} (\mathbf{x}_i - \hat{\boldsymbol{\mu}})(\mathbf{x}_i - \hat{\boldsymbol{\mu}})^\top,$$

где $\hat{\boldsymbol{\mu}} = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathbf{x}_i$ — выборочное среднее.

- › Для гауссовских систем оценка $\hat{\Sigma}$ является несмещенной и состоятельной

Недостатки стандартных оценок

- › Качество оценивания зависит от соотношения объема выборки ℓ и размерности пространства n :

$$\begin{cases} \text{если } \ell \gg n, & \text{то все хорошо,} \\ \text{если } \ell \leq n, & \text{то оценка } \hat{\Sigma} \text{ нестабильна.} \end{cases}$$

- › Для $\ell \leq n$ использование выборочной оценки приводит к тому, что матрица $\hat{\Sigma}$ вырождена (невозможно вычислить обратную $\hat{\Theta} = \hat{\Sigma}^{-1}$) (докажите!)
- › Стандартную оценку не получится использовать в разреженной модели (вообще говоря, все коэффициенты матрицы будут ненулевыми)
- › Больше на https://en.wikipedia.org/wiki/Estimation_of_covariance_matrices

Неформальная постановка задачи

- › Разумно иметь минимальную по сложности модель (например, графическую), которая адекватно описывает данные
- › **Задача:** по заданной выборке данных \mathbf{X}^ℓ найти такую корреляционную матрицу, чтобы получить **как можно более разреженный** граф зависимостей между переменными
- › Целью является как выявление (разреженной) матрицы зависимостей между переменными, так и получение регуляризованной оценки ковариационной матрицы
- › Условие разреженности обеспечивается ℓ_1 -регуляризацией решения

Формальная постановка задачи

- › Пусть задана выборка $\mathbf{X}^\ell = \{\mathbf{x}_i\}_{i=1}^\ell$, $\mathbf{x}_i \in \mathbb{R}^n$. Запишем правдоподобие в предположениях гауссовской модели:

$$\mathcal{L}(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = (2\pi)^{-\frac{\ell n}{2}} \prod_{i=1}^{\ell} [\det \boldsymbol{\Sigma}]^{-\frac{1}{2}} \exp \left\{ -\frac{1}{2} (\mathbf{x}_i - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}) \right\}$$

Эквивалентно (trace trick, докажите!):

$$\log \mathcal{L}(\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \text{const} - \frac{\ell}{2} \log \det \boldsymbol{\Sigma} - \frac{1}{2} \text{tr} [\boldsymbol{\Sigma}^{-1} \mathbf{S}],$$

где $\mathbf{S} = \sum_{i=1}^{\ell} (\mathbf{x}_i - \hat{\boldsymbol{\mu}})(\mathbf{x}_i - \hat{\boldsymbol{\mu}})^\top$

- › Стандартная задача вида $\log \mathcal{L} \rightarrow \max_{\boldsymbol{\mu}, \boldsymbol{\Sigma}}$ дает (докажите!)

$$\hat{\boldsymbol{\mu}}_{\text{MLE}} = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathbf{x}_i, \quad \hat{\boldsymbol{\Sigma}}_{\text{MLE}} = \frac{1}{\ell - 1} \sum_{i=1}^{\ell} (\mathbf{x}_i - \hat{\boldsymbol{\mu}}_{\text{MLE}})(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_{\text{MLE}})^\top,$$

Формальная постановка задачи

- › Итак, стандартно $\log \mathcal{L} \rightarrow \max_{\mu, \Sigma}$ и решается задача на максимум:

$$\hat{\Sigma}_{\text{MLE}} = \arg \max_{\mathbf{X} \text{ is PSD}} \left[\text{const} - \frac{\ell}{2} \log \det \mathbf{X} - \frac{1}{2} \text{tr}(\mathbf{S} \mathbf{X}^{-1}) \right],$$

- › Для разреживания обратной ковариационной матрицы часто применяется ℓ_1 -регуляризация
- › Таким образом, требуется найти ℓ_1 -регуляризованную ОМП:

$$\hat{\Sigma}_{\ell_1}^{-1} = \arg \max_{\mathbf{X} \text{ is PSD}} \left[\log \det \mathbf{X} - \text{tr}(\mathbf{S} \mathbf{X}) - \lambda \|\mathbf{X}\|_1 \right]$$

- › λ : баланс между максимизацией правдоподобия и разреженностью

Вспомним: ℓ_1 -регуляризация

- › L2 регуляризация для многомерной линейной регрессии

$$\|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2 + \alpha\|\mathbf{w}\|^2 \rightarrow \min_{\mathbf{w} \in \mathbb{R}^d}$$


- › L1 регуляризация (LASSO)

$$\|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2 + \alpha\|\mathbf{w}\|_1 \rightarrow \min_{\mathbf{w} \in \mathbb{R}^d}$$

- › L1/L2 регуляризация (Elastic Net)

$$\|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2 + \alpha_1\|\mathbf{w}\|_1 + \alpha_2\|\mathbf{w}\|_2^2 \rightarrow \min_{\mathbf{w} \in \mathbb{R}^d}$$

Геометрическая интерпретация регуляризаторов



Изображение: http://www.ds100.org/sp17/assets/notebooks/linear_regression/Regularization.html

Интерпретация регуляризаторов



Рис.: Многомерное пространство параметров



Рис.: Регуляризованная модель

Известные подходы к получению решения

- › Требуется найти ℓ_1 -регуляризованную ОМП:

$$\hat{\Sigma}^{-1} = \arg \max_{\mathbf{X} \text{ is PSD}} \left[\log \det \mathbf{X} - \text{tr}(\mathbf{S}\mathbf{X}) - \lambda \|\mathbf{X}\|_1 \right]$$

- › Разреженность, обратимость, ...
- › Блочно-координатный оптимизационный алгоритм [Banerjee et al., 2008]
- › Графическое LASSO [Friedman et al., 2008]
- › QUIC [Hsieh et al., 2014]

Оптимизация в пространстве матриц

Полезное определение

- › Пусть $\|\cdot\|$ — норма в \mathbb{R}^n и $\mathbf{z}, \mathbf{x} \in \mathbb{R}^n$.
- › Сопряженная $\|\cdot\|$ «дуальная норма», обозначаемая $\|\cdot\|_*$, определяется как

$$\|\mathbf{z}\|_* = \sup_{\|\mathbf{x}\| \leq 1} \mathbf{z}^\top \mathbf{x}$$

- › Аналогичное определение существует для матричных норм

Алгоритм [Banerjee et al., 2008] (трюки)

- › Требуется найти

$$\max_{\mathbf{X} \text{ is PSD}} \left[\log \det \mathbf{X} - \text{tr}(\mathbf{S}\mathbf{X}) - \lambda \|\mathbf{X}\|_1 \right]$$

- › Используя равенство $\|\mathbf{X}\|_1 = \max_{\|\mathbf{U}\|_\infty \leq 1} \text{tr}(\mathbf{X}\mathbf{U})$:

$$\max_{\mathbf{X} \text{ is PSD}} \min_{\|\mathbf{U}\|_\infty \leq \lambda} \left[\log \det \mathbf{X} - \text{tr}(\mathbf{X}, \mathbf{S} + \mathbf{U}) \right]$$

- › Можем поменять местами max и min и аналитически найти максимум внутренней функции $\log \det \mathbf{X} - \text{tr}(\mathbf{X}, \mathbf{S} + \mathbf{U})$
- › Результат: $\mathbf{X} = -\mathbf{S} - \mathbf{U}$, при этом $\text{tr}(\mathbf{X}, \mathbf{S} + \mathbf{U}) = n$

Алгоритм [Banerjee et al., 2008] (трюки)

- › Приходим к оптимизационной задаче:

$$\min_{\|U\|_{\infty} \leq \lambda} \left[-\log \det(\mathbf{S} + \mathbf{U}) - n \right]$$

- › Соответствующая задача с ограничениями ($\mathbf{W} = \mathbf{S} + \mathbf{U}$):

$$\hat{\Sigma} = \max \left\{ \log \det \mathbf{W} : \|\mathbf{W} - \mathbf{S}\|_{\infty} \leq \lambda \right\}$$

называется дуальной задачей

- › Задача гладкая и выпуклая по элементам $(\mathbf{W})_{ij}$
- › Минус — высокая размерность задачи $n(n+1)/2$: для эффективного решения простыми оптимизационными методами должно быть выполнено $n \sim 1 \dots 10$ (например, ε -субоптимальный метод дает сложность $O(n^6 \log(1/\varepsilon))$)

Блочный координатный спуск

- › Обозначим $A_{\setminus k \setminus j}$ матрицу, полученную из A вычеркиванием j -той строки и k -того столбца
- › Пусть k — номер обновления всей матрицы W
- › Алгоритм оптимизационного поиска W : обновляем одну строку/столбец матрицы W на каждой итерации по строкам/столбцам $j = 1, \dots, n$

Блочный координатный спуск

› Инициализация: установить $\mathbf{W}^{(0)} = \mathbf{S} + \lambda \mathbf{I}$

Блочный координатный спуск

› Инициализация: установить $\mathbf{W}^{(0)} = \mathbf{S} + \lambda \mathbf{I}$

› Итерации:

1. Пусть $\mathbf{W}^{(j-1)}$ — текущая версия \mathbf{W} . Решим задачу (box-constrained quadratic program (QP))

$$\hat{\mathbf{y}} = \arg \min_{\mathbf{y}} \left\{ \mathbf{y}^T \mathbf{W}_{\setminus j \setminus j}^{(j-1)} \mathbf{y} : \|\mathbf{y} - \mathbf{S}_j\|_{\infty} \leq \lambda \right\}$$

Блочный координатный спуск

› Инициализация: установить $\mathbf{W}^{(0)} = \mathbf{S} + \lambda \mathbf{I}$

› Итерации:

1. Пусть $\mathbf{W}^{(j-1)}$ — текущая версия \mathbf{W} . Решим задачу (box-constrained quadratic program (QP))

$$\hat{\mathbf{y}} = \arg \min_{\mathbf{y}} \left\{ \mathbf{y}^T \mathbf{W}_{\setminus j \setminus j}^{(j-1)} \mathbf{y} : \|\mathbf{y} - \mathbf{S}_j\|_{\infty} \leq \lambda \right\}$$

2. Обновим $\mathbf{W}^{(j)} \leftarrow \mathbf{W}^{(j-1)}$ с заменой строки \mathbf{W}_j на $\hat{\mathbf{y}}$

Блочный координатный спуск

› Инициализация: установить $\mathbf{W}^{(0)} = \mathbf{S} + \lambda \mathbf{I}$

› Итерации:

1. Пусть $\mathbf{W}^{(j-1)}$ — текущая версия \mathbf{W} . Решим задачу (box-constrained quadratic program (QP))

$$\hat{\mathbf{y}} = \arg \min_{\mathbf{y}} \{ \mathbf{y}^\top \mathbf{W}_{\setminus j \setminus j}^{(j-1)} \mathbf{y} : \|\mathbf{y} - \mathbf{S}_j\|_\infty \leq \lambda \}$$

2. Обновим $\mathbf{W}^{(j)} \leftarrow \mathbf{W}^{(j-1)}$ с заменой строки \mathbf{W}_j на $\hat{\mathbf{y}}$

› После пробега всех $j = 1, \dots, n$ установим $\widehat{\mathbf{W}}^{(0)} \leftarrow \mathbf{W}^{(n)}$

› Критерий остановки: $\text{tr}((\widehat{\mathbf{W}}^{(0)})^{-1} \mathbf{S}) - p + \lambda \|(\widehat{\mathbf{W}}^{(0)})^{-1}\|_1 \leq \varepsilon$

Результат алгоритма




Рис.: A: разреженная матрица Σ^{-1} ;
B: оценка \hat{S}^{-1} по выборке объема $\ell = 60$;
C: оценка $\hat{\Sigma}_{\ell_1}^{-1}$ с $\lambda = 0.1$.
Размерность задачи $n = 30$.

Связь λ и вероятности восстановления

- › Рассмотрим истинную неизвестную графическую модель для заданного распределения
- › Для заданного узла k пусть C_k — его компонента связности
- › Пусть \hat{C}_k^λ — оценка его компоненты связности с параметром регуляризации λ
- › **Утверждение.** Пусть параметр λ выбран так, что

$$\lambda(\alpha) = \max_{i>j}(\hat{\sigma}_i \hat{\sigma}_j) \frac{t_{n-2}(\alpha/2n^2)}{n-2+t_{n-2}(\alpha/2n^2)}.$$

Тогда вероятность того, что хотя бы одна компонента связности в графической модели будет восстановлена неверно не превосходит α :

$$P(\exists k : \hat{C}_k^\lambda \not\subseteq C_k) \leq \alpha).$$

Графическое Lasso

Графическое Lasso [Friedman et al., 2008]

- › Можно заметить (см. дуальность норм), что задача на минимум

$$\hat{\mathbf{y}} = \arg \min_{\mathbf{y}} \{ \mathbf{y}^T \mathbf{W}_{\setminus j \setminus j}^{(j-1)} \mathbf{y} : \|\mathbf{y} - \mathbf{S}_j\|_{\infty} \leq \lambda \}$$

имеет дуальную задачу

$$\hat{\mathbf{y}} = \arg \min_{\mathbf{y}} [\mathbf{y}^T \mathbf{W}_{\setminus j \setminus j}^{(j-1)} \mathbf{y} - \mathbf{S}_j^T \mathbf{y} + \lambda \|\mathbf{y}\|_1]$$

- › Обозначим $\mathbf{Q} = (\mathbf{W}_{\setminus j \setminus j}^{(j-1)})^{1/2}$, $\mathbf{b} = \frac{1}{2} \mathbf{Q}^{-1} \mathbf{S}_j$, тогда

$$\hat{\mathbf{y}} = \arg \min_{\mathbf{y}} \left[\frac{1}{2} \|\mathbf{Q} \mathbf{y} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{y}\|_1 \right]$$

— известная как Lasso регуляризованная задача на минимум

Графическое Lasso: алгоритм

- › Инициализация: установить $\mathbf{W} = \mathbf{S} + \lambda \mathbf{I}$
- › Для каждого $j = 1, 2, \dots, n, 1, 2, \dots$ решить Lasso-задачу

$$\hat{\mathbf{y}} = \arg \min_{\mathbf{y}} [\|\mathbf{Q}\mathbf{y} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{y}\|_1],$$

получив оценки $\hat{\mathbf{y}}, \mathbf{w} = \mathbf{Q}^\top \mathbf{Q} \hat{\mathbf{y}}$

- › Заполнить j -ую строку матрицы \mathbf{W} вектором \mathbf{w}
- › Повторять до сходимости

Графическое Lasso: эксперименты






Рис.: Пример данных проточной цитометрии на $n = 11$ протеинах и $\ell = 7466$ клетках.

Friedman, Jerome, Trevor Hastie, and Robert Tibshirani. "Sparse inverse covariance estimation with the graphical lasso." *Biostatistics* 9.3 (2008): 432-441.


Графическое Lasso: эксперименты




L1 norm= 2.27182




L1 norm= 0.08915




L1 norm= 0.04251



L1 norm= 0.02171



L1 norm= 0.01611



L1 norm= 0.01224

Алексей Артемов

Рис.: Результаты применения графического Lasso к данным проточной цитометрии.

Friedman, Jerome, Trevor Hastie, and Robert Tibshirani. "Sparse inverse covariance estimation with the graphical

Насколько быстро граф. Lasso?




Рис.: Сравнение среднего времени работы двух оптимизационных алгоритмов: **блочного координатного спуска** и **графического lasso**.

Friedman, Jerome, Trevor Hastie, and Robert Tibshirani. "Sparse inverse covariance estimation with the graphical lasso." *Biostatistics* 9.3 (2008): 432-441.

Алексей Артемов

Современный подход: QUIC [Hsieh et al., 2014]

- › QUIC: QUadratic approximation of Inverse Covariance matrices
- › Метод второго порядка для решения ℓ_1 -регуляризованных задач на ОМП в гауссовских предположениях
- › Повторяются шаги Ньютоновского метода, использующие итеративную квадратичную оценку гауссовского NLL
- › Специальный тип итераций (ускорение типа Armijo-rule) обеспечивает положительную определенность решения
- › Идентификация блочной структуры для эффективных итераций
- › Снижение сложности координатного спуска с $O(n^2)$ до $O(n)$
- › Реализации на R, MATLAB, `scikit-learn`

Резюме лекции

- › Иногда бывает необходимо оценивать ковариационные матрицы
- › ℓ_1 -регуляризация оценки помогает сделать оценки разреженными
- › Блочно-координатный метод и графическое lasso — эффективные (хотя немножко устаревшие) алгоритмы оптимизации регуляризованного правдоподобия
- › Более современные методы QUIC доступны в широко известных пакетах

Литература



Banerjee, O., Ghaoui, L. E., and d'Aspremont, A. (2008).

Model selection through sparse maximum likelihood estimation for multivariate gaussian or binary data.

Journal of Machine learning research, 9(Mar):485–516.



Friedman, J., Hastie, T., and Tibshirani, R. (2008).

Sparse inverse covariance estimation with the graphical lasso.

Biostatistics, 9(3):432–441.



Hsieh, C.-J., Sustik, M. A., Dhillon, I. S., and Ravikumar, P. (2014).

Quic: quadratic approximation for sparse inverse covariance estimation.

The Journal of Machine Learning Research, 15(1):2911–2947.